Reporte de los modelos utilizados para el proyecto HackODS, equipo DERRE

Claudio Flores Guzmán
Emilio Axel Salas Palcios
Noel Pérez Martínez

24 de abril de 2026

Modelo 1.

Planteamiento del modelo 1

El objetivo del modelo es simular la dinámica de las ballenas grises entre las Lagunas Ojo de Liebre y San Ignacio, donde pasan su temporada reproductiva en el invierno. Rogers et al., 2023. Esto nos permitirá simular su dinámica y ajustar el modelo al dataset de los censos de ballenas grises en las lagunas.

Se considera la cadena de Markov $\{X_t\}_{t\in\mathbb{N}}$ no homogénea de 4 estados dados por

$$\begin{aligned} S_1 &= \textbf{Ojo de Liebre} \\ S_2 &= \textbf{San Ignacio} \\ S_3 &= \textbf{Ruta Migratoria} \\ S_4 &= \textbf{Deceso} \end{aligned}$$

Con las siguiente matrices de transición
Caso (1): $t \equiv 0 \pmod 3$ (Etapa reproductiva)

$$P(t) = \begin{pmatrix} 1-0{,}42-\alpha_1 & 0{,}42 & 0 & \alpha_1 \\ 0{,}42 & 1-0{,}42-\alpha_1 & 0 & \alpha_1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Donde las probabilidades de transición de cambiar de una isla a otra están documentadas en IUCN-MMPATF, 2023.

Caso (2): $t \equiv 1 \pmod 3$ (Etapa de Transición Fuera de las Islas)

$$P(t) = \begin{pmatrix} 0 & 0 & 1-\alpha_2 & \alpha_2 \\ 0 & 0 & 1-\alpha_2 & \alpha_2 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Hay que encontrar α_2 de la literatura y citarlo o aproximarlo en el MCMC.

Caso (3) $t \equiv 2 \pmod 3$ (Etapa de Transición a las Islas)

$$P(t) = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0{,}70 & 0{,}14 & 0 & 0{,}16 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

De donde las probabilidades de transición fueron estudiadas en IUCN-MMPATF, 2023.

Se puede definir el proceso $Y_t = X_{3t}$. Que capturaría la dinámica de las ballenas solamente en las etapas reproductivas y permitiría simular esta dinámica.

Ajuste del modelo 1

Se buscarán estimar los parámetros α_1, α_2, π. Donde π es una distribución estacionaria de la cadena de Markov Y_n, $P\pi = \pi$, con P la matriz de transición de la cadena de Markov Y_n. En este caso $P = P(3t+2)P(3t+1)P(3t)$ para $t \in \mathbb{N}$. Se supondrá que los parámetros están distribuidos de la forma

$$\begin{aligned} \alpha_1 &\sim \text{Beta}\left(\hat{\alpha_1}, \hat{\beta_1}\right) \\ \alpha_2 &\sim \text{Beta}\left(\hat{\alpha_2}, \hat{\beta_2}\right) \\ \lambda &\sim \text{Beta}\left(\hat{\alpha_\lambda}, \hat{\beta_\lambda}\right) \end{aligned}$$

Donde λ es un parámetro auxiliar para ajustar la distribución estacionaria de la siguiente forma. Se pueden estimar dos distribuciones estacionarias, la de llegada π_1 y durante la etapa de reproducción π_2. En IUCN-MMPATF, 2023 se menciona que al llegar a la zona reproductiva un 70 % de las ballenas grises se dirigen a la Laguna Ojo de Liebre mientras que un 14 % se dirige a la Laguna San Ignacio. Usando esto, se tiene que si $\pi_1 = (\pi_{11}, \pi_{12})$

$$\pi_{11} = \frac{0{,}70}{(0{,}70 + 0{,}14)} = \frac{5}{6}$$

$$\pi_{12} = \frac{0{,}14}{(0{,}70 + 0{,}14)} = \frac{1}{6}$$

Y para la distribución estacionaria durante la etapa reproductiva, se considera la submatriz

$$\begin{pmatrix} 1 - 0{,}42 - \alpha_1 & 0{,}42 \\ 0{,}42 & 1 - 0{,}42 - \alpha_1 \end{pmatrix} \begin{pmatrix} \pi_{21} \\ \pi_{22} \end{pmatrix} = \begin{pmatrix} \pi_{21} \\ \pi_{22} \end{pmatrix}$$

Nótese que dado que esta es una matriz de probabilidad y es una matriz simétrica el determinante está dado de la forma $A^2 - B^2 = (A - B)(A + B) \neq 0$ y la distribución estacionaria es única. La solución del sistema de ecuaciones está dada por $\pi_{21} = \pi_{22} = 0{,}5$.

Nótese que ambas distribuciones son distintas, entonces usamos el parámetro λ auxiliar para estimar la distribución estacionaria global de la siguiente forma

$$\pi = (1-\lambda)\pi_1 + \lambda\pi_2$$

Para la estimación de los parámetros se utilizaron métodos de MCMC implementados en la librería de Python PyMC. Los priors del MCMC fueron los siguientes

$$\alpha_1 \sim \text{Beta}\,(2, 50)$$

Puesto que se observa una mortalidad baja Carretta, 2020

$$\alpha_2 \sim \text{Beta}(1{,}5, 100)$$

De la misma forma, usando la distribución beta con su uso clásico para modelar tasas de supervivencia, se seleccionó este prior usando Carretta et al., 2022.

$$\lambda \sim \text{Beta}(2{,}0, 8)$$

Donde se elige suponiendo que habrá más peso de la distribución de llegada puesto que las ballenas pasan más tiempo fuera de las lagunas que dentro de las lagunas.

Además se añadió un parámetro κ que capturará variabilidad más allá de los factores analizados como

$$\kappa \sim \text{Exp}(0{,}01)$$

Para ajustar el modelo a los datos disponibles de observaciones de ballenas en la Laguna Ojo de Liebre, SEMARNAT, 2025 se observa que la variable aleatoria $\mathcal{O}$ distribuida de la forma

$$\mathcal{O} \sim \text{Beta Binomial}\,(N, \alpha = \kappa\hat{\pi}_t, \beta = \kappa(1-\hat{\pi}_t))$$

Donde $\hat{\pi} = \pi$ (π definido anteriormente), N es la cantidad de ballenas totales, obtenida de nuestros datos. Se debería de ajustar a nuestros datos de ballenas en la Laguna Ojo de Liebre.

Para ajustar el modelo anterior a los datos se utilizó el método de Markov Chain Monte Carlo (MCMC) con 4 cadenas de 2000 muestras cada una y 1500 iteraciones de calentamiento (*tune*), implementado en la librería PyMC de Python. Los resultados del diagnóstico de convergencia se presentan en el Cuadro 1.

Cuadro 1: Diagnóstico de convergencia MCMC — Modelo de ballenas grises.

Parámetro	**Media**	**DE**	**Mediana**	**IC 90 %**	**ESS**	$\hat{R}$
α_1	0.038	0.026	0.033	[0,007, 0,089]	5898	1.001
α_2	0.015	0.012	0.012	[0,002, 0,038]	6503	1.000
λ	0.052	0.026	0.049	[0,015, 0,099]	5275	1.001
κ	45.924	12.300	—	[24,858, 69,515]	8121	1.001
p_{ciclo}	0.947	0.028	0.953	[0,894, 0,983]	7537	1.000

Todos los valores $\hat{R}$ son menores a 1,01 y los tamaños de muestra efectivos (ESS) superan las 5000 muestras, lo que indica convergencia satisfactoria de todas las cadenas. La proporción esperada de ballenas en la Laguna Ojo de Liebre bajo el modelo ajustado es $\hat{\pi} = 0{,}817$ (IC 90 %: [0,800, 0,828]), en estrecha concordancia con la proporción media observada en los datos de 0,824.

Modelo 2.

Planteamiento del modelo 2

El objetivo del modelo es describir la dinámica entre una especie indicadora del bienestar del ecosistema costero mexicano y la presión pesquera ejercida sobre él. Se considera el sistema de mapas de Ricker semi-acoplado en tiempo discreto

$$\begin{aligned} H(t+1) &= H(t)\exp\bigl(r(1-H(t)/K) - aP(t)\bigr) + \varepsilon_H \\ P(t+1) &= P(t)\exp\bigl(f(1-P(t)/C)\bigr) + \varepsilon_P \end{aligned}$$

donde $H(t)$ representa la abundancia normalizada de la especie indicadora (pelícanos) y $P(t)$ la presión pesquera normalizada (embarcaciones registradas), ambas en escala $[0, 1]$ mediante normalización min-max. Los parámetros $r > 0$ y $K = 1$ corresponden a la tasa de crecimiento intrínseco y la capacidad de carga de la especie indicadora; $a > 0$ es la tasa de impacto de la presión pesquera sobre el ecosistema; $f > 0$ y $C = 1$ son la tasa de crecimiento autónomo y la capacidad de carga de la flota pesquera. Los términos ε_H y ε_P capturan el ruido de proceso en cada ecuación.

El carácter semi-acoplado del sistema refleja la hipótesis central del modelo: la flota pesquera crece por razones económicas y políticas independientes del estado del ecosistema, mientras que el ecosistema sí es afectado por la presión de la flota. La ecuación de P es por tanto autónoma, lo que permite estimar f de forma aislada en una primera etapa. El modelo de observación supone

$$\begin{aligned} H_{\text{obs}}(t) &\sim \mathcal{N}(H(t),\, \sigma_H) \\ P_{\text{obs}}(t) &\sim \mathcal{N}(P(t),\, \sigma_P) \end{aligned}$$

donde σ_H y σ_P cuantifican el ruido de observación en cada serie.

Ajuste del modelo 2

Los parámetros del modelo se estimaron conjuntamente ajustando el sistema completo de ecuaciones mediante MCMC con 4 cadenas de 2000 muestras y 1000 iteraciones de calentamiento. Los cinco parámetros r, a, f, σ_H y σ_P se infirieron de forma simultánea a partir de las trayectorias observadas de H y P. Los resultados del diagnóstico de convergencia se presentan en el Cuadro 2.

Cuadro 2: Diagnóstico de convergencia MCMC — Modelo presa-depredador.

Parámetro	**Media**	**DE**	**Mediana**	**IC 90 %**	**ESS**	$\hat{R}$
r	1.435	0.976	1.205	[0.231, 3.372]	1930	1.002
a	2.560	1.759	2.124	[0.452, 6.057]	1928	1.002
f	0.047	0.010	0.047	[0.030, 0.064]	3036	1.001
σ_H	0.269	0.039	0.265	[0.212, 0.338]	4431	1.001
σ_P	0.200	0.030	0.197	[0.158, 0.254]	4202	1.002

Todos los valores $\hat{R}$ son menores a 1.01 y los tamaños de muestra efectivos superan las 1900 muestras en todos los parámetros, indicando convergencia satisfactoria. El parámetro f presenta el mayor ESS (3036) y el intervalo de credibilidad más estrecho ([0.030, 0.064]), lo que confirma que el crecimiento autónomo de la flota es el mecanismo mejor identificado por los datos. Los intervalos amplios de r y a reflejan el alto nivel de ruido de observación cuantificado por $\sigma_H = 0{,}265$, que ocupa una fracción sustancial de la varianza total de H. El ajuste de las trayectorias medianas arroja $R^2 = 0{,}10$ para H y $R^2 = 0{,}34$ para P, lo que indica que el modelo captura una proporción moderada de la variabilidad en la dinámica del depredador pero limitada en la de la presa.

Referencias

Carretta, J. V. (2020, julio). *Estimates of marine mammal, sea turtle, and seabird bycatch in the California large-mesh drift gillnet fishery: 1990-2018* (NOAA Technical Memorandum N.º NOAA-TM-NMFS-SWFSC-632). National Oceanic y Atmospheric Administration (NOAA), National Marine Fisheries Service (NMFS), Southwest Fisheries Science Center. La Jolla, CA. https://repository.library.noaa.gov/view/noaa/25413

Carretta, J. V., Oleson, E. M., Forney, K. A., Muto, M. M., Weller, D. W., Lang, A. R., Baker, J., Hanson, B., Orr, A. J., Barlow, J., Moore, J. E., & Brownell, R. L. (2022). *Gray Whale (Eschrichtius robustus): Eastern North Pacific Stock* (inf. téc. N.º NOAA-TM-NMFS-SWFSC-663). NOAA National Marine Fisheries Service, Southwest Fisheries Science Center. https://repository.library.noaa.gov

IUCN-MMPATF. (2023). *Western Baja California Lagoons and Coastal Waters IMMA Factsheet*. IUCN Joint SSC/WCPA Marine Mammal Protected Areas Task Force. Consultado el 21 de mayo de 2024, desde https://www.marinemammalhabitat.org/factsheets/western-baja-california-lagoons-and-coastal-waters-imma/

Rogers, L., Auth, T., Brodeur, R., Burke, B., Daly, E., Dewitt, T., Fisher, J., Gambatese, S., Hinton, S., Iwasaki, J., Morgan, C., Munch, S., Thompson, A., Thorson, J., Ward, E., Whitmire, A., Williams, G., & Zeman, S. (2023). *Ecosystem Status Report 2023: California Current* (Technical Memorandum). National Oceanic y Atmospheric Administration (NOAA). https://doi.org/10.25923/246k-7589

SEMARNAT. (2025). *Población registrada de ballena gris* (Compendio de Estadísticas Ambientales. Indicadores de Biodiversidad) (Información proporcionada por la CONANP. Revisión: Noviembre 2025). Secretaría de Medio Ambiente y Recursos Naturales. Sistema Nacional de Información Ambiental y de Recursos Naturales (SNIARN). Consultado el 20 de mayo de 2024, desde http://dgeiawf.semarnat.gob.mx:8080/ibi_apps/WFServlet?IBIF_ex=D3_BIODIV02_06&IBIC_user=dgeia_mce&IBIC_pass=dgeia_mce